



UNIVERSIDAD ARTURO PRAT
DEL ESTADO DE CHILE

CONOCIMIENTO Y TERRITORIO

FACULTAD DE INGENIERÍA Y ARQUITECTURA
INGENIERÍA CIVIL EN COMPUTACIÓN E INFORMÁTICA



ANÁLISIS DE PATRONES EN EL INCREMENTO DE LA TASA DE SUICIDIOS EN BRASIL UTILIZANDO TÉCNICAS DE MINERÍA DE DATOS

INTELIGENCIA DE NEGOCIOS

INTEGRANTES:

Héctor Aldea
Jorge Colque
Daniel González

IQUIQUE-CHILE
2023

Índice de Contenidos

I. DOMINIO DEL PROBLEMA.....	4
1.1. Contexto.....	4
1.2. Objetivos del negocio	4
II. EVALUACIÓN DE LA SITUACIÓN	5
2.1. Recursos.....	5
2.1.1. Recursos Humanos	5
2.1.2. Hardware	6
2.1.3. Software.....	6
2.2. Requerimientos	7
2.3. Supuestos	7
2.4. Restricciones.....	8
2.5. Riesgos.....	9
2.5.1. Riesgos del Negocio	9
2.5.2. Riesgos Organizacionales.....	9
2.5.3. Riesgos Financieros.....	10
2.5.4. Riesgos Técnicos	10
2.5.5. Riesgos relacionados a los datos y la fuente de datos	11
2.6. Contingencias.....	11
2.7. Terminología.....	13
2.8. Especificación de costos y beneficios.....	16
III. OBJETIVOS DE DATA MINING	18
3.1. Objetivos.....	18
3.2. Criterios de éxito.....	19
3.3. Plan del proyecto.....	19
IV. ENTENDIMIENTO DE LOS DATOS.....	21
4.1. Recolección inicial de los datos	21
4.1.1. Criterios de selección.....	22
4.1.2. Inserción de datos	23
4.2. Descripción de herramientas utilizadas	24
4.3. Descripción detallada de los datos	25
4.3.1. Formato y rango de los datos.....	25

4.3.2.	Comprensión de los atributos en términos del negocio	26
4.3.3.	Estadísticos descriptivos.....	26
4.3.4.	Calidad de los datos.....	36
V.	PREPARACIÓN DE DATOS	36
5.1.	Transformación de datos.....	36
5.2.	Selección de datos.....	37
5.3.	Limpieza de datos	38
5.4.	Integración de datos	38
VI.	MODELAMIENTO	39
6.1.	Selección de técnicas de modelamiento.....	40
6.1.1.	Segmentación (Clustering)	40
6.1.2.	Coeficientes de Correlación.....	41
6.2.	Generación diseño de prueba	41
6.3.	Construcción de los modelos	42
6.3.1.	Configuración de parámetros.....	42
6.3.2.	Modelos	46
6.3.3.	Visualización de modelos	47
6.4.	Patrones obtenidos	52
VII.	EVALUACIÓN.....	53
7.1.	Evaluación de resultados.....	53
7.1.1.	Descripción de métodos de validación	53
7.1.2.	Validación y comparación de resultados	54
7.2.	Determinación de próximos pasos	60
VIII.	DESPLIEGUE	61
8.1.	Modelos Descriptivos	61
IX.	CONCLUSIONES	66
X.	ANEXOS.....	67

I. DOMINIO DEL PROBLEMA

1.1. Contexto

Brasil se caracteriza por ser un país con amplia diversidad cultural y socioeconómica, con una población de más de 200 millones de habitantes. Desafortunadamente también enfrenta desafíos en cuanto a salud mental y bienestar psicológico. Según estadísticas recientes, este país ha experimentado un incremento en las tasas de suicidios durante los últimos años, lo cual constituye una preocupación seria para el ministerio de salud de Brasil.

El aumento constante de las tasas de suicidio en el país ha generado una creciente atención hacia esta problemática, así como la necesidad de abordar las causas de este hecho y buscar soluciones efectivas para ayudar a prevenir esta tragedia.

Brasil es conocido por ser uno de los países con mayor desigualdad socioeconómica, lo que puede tener un impacto significativo en la salud mental de su población. Las personas que viven en condiciones de extrema pobreza con falta de acceso a servicios básicos y oportunidades educativas y laborales limitadas enfrentan un mayor riesgo de sufrir problemas relacionados a la salud mental. Este y otros factores pueden ser fundamentales a la hora de llevar a cabo esta decisión. La identificación y prevención temprana de los factores de riesgo de suicidio son cruciales para abordarlo a tiempo, así como también, la promoción de la salud mental, la educación pública sobre el suicidio y el fortalecimiento de la red de apoyo social.

En el presente proyecto, se analizarán los datos relacionados a los suicidios ocurridos en Brasil entre los años 2010 a 2019 obtenidos de las bases de datos del ministerio de salud de Brasil, para extraer información que sea útil para la toma de decisiones en las campañas de prevención del suicidio. Para lo mencionado, es necesario realizar previamente un estudio para observar el comportamiento de los datos y obtener patrones a través de estos.

1.2. Objetivos del negocio

DATASUS el Departamento de Informática del Sistema Único de Salud, es un organismo público brasileño subordinado a la Fundación Nacional de Salud (Funasa). Esta agencia

recibe y almacena los datos producidos por el ministerio y por las secretarías de salud estatales de todo Brasil. Además, asesora a las secretarías municipales de salud en el establecimiento de sistemas de información y en la incorporación de tecnologías que permitan una mejora en la gestión de datos e información de carácter estratégico.

En este contexto, se pretende emplear los datos de acceso público proporcionados por el Ministerio de Salud de Brasil, específicamente la información sobre los casos de suicidio registrados entre 2010 a 2019.

El objetivo principal del negocio es mejorar **focalizar** las compañías focalizadas en la prevención del suicidio. Para esto, es que se realizara un estudio para conocer los diferentes grupos de riesgo en base a la identificación de patrones de similitud entre los diferentes casos registrados utilizando algoritmos de correlación y agrupación.

CORRECCIÓN: Redacción de objetivo de negocio.

II. EVALUACIÓN DE LA SITUACIÓN

2.1. Recursos

2.1.1. Recursos Humanos

Tabla 1 - Integrante Equipo de Trabajo

Nombre	Héctor Aldea N.
Cargo en el proyecto	Analista Data Mining
Tipo de participación	Directa

Tabla 2 - Integrante Equipo de Trabajo

Nombre	Jorge Colque C.
Cargo en el proyecto	Analista Data Mining
Tipo de participación	Directa

Tabla 3 - Integrante Equipo de Trabajo

Nombre	Daniel González C.
---------------	---------------------------

Cargo en el proyecto	Analista Data Mining
Tipo de participación	Directa

Tabla 4 - Asesor Equipo de Trabajo

Nombre	Francisco García B.
Cargo en el proyecto	Consultoría y coaching Data Mining
Tipo de participación	Asesoría

2.1.2. Hardware

Para este proyecto se considera el uso de los siguientes elementos de Hardware:

Tabla 5 – Notebook MSI

Recurso	Notebook
Marca	MSI
Modelo	GP65 Leopard 9SD
Características	• SO: Windows 10® Pro • Procesador Intel Core i7-9750H • 16GB de Memoria RAM

Tabla 6 – Notebook HP

Recurso	Notebook Corporativo
Marca	HP
Modelo	ZBook 15 G5
Características	• SO: Windows 10 Enterprise • Procesador Intel® Xeon® E5-2186M 2.90GHz • 64 GB de Memoria RAM (4x16)

2.1.3. Software

Los softwares que se utilizarán para el presente proyecto son los siguientes:

Tabla 7 - Anaconda 3

Nombre aplicación	Anaconda 3
Tipo de aplicación	Entorno de Python
Justificación de uso	Previsualizar el conjunto de datos para el análisis de variables.
Versión	2023.03

Tabla 8 - Knime

Nombre aplicación	Knime
Tipo de aplicación	Modelado ETL
Justificación de uso	Compatibilidad, flexibilidad y facilidad de uso.
Versión	4.0

2.2. Requerimientos

Tabla 9 - Requerimiento 01

Código Requerimiento	RQ-01
Nombre Requerimiento	Obtener patrones de cualidades según casos de suicidio.
Descripción	Estudiar patrones que se presenten en distintos casos de suicidio para identificar relaciones entre las variables de cada caso.

Tabla 10 - Requerimiento 02

Código Requerimiento	RQ-02
Nombre Requerimiento	Identificar grupos de variables similares
Descripción	Señalar relaciones entre grupos de variables presentes en los casos de suicidio.

CORRECCIÓN: Los requerimientos deben tener relación con lo que se requiere para el proyecto.

2.3. Supuestos

A continuación, se presentan los supuestos en torno al proyecto:

Tabla 11 - Supuesto 01

Código Supuesto	SU-01
Descripción	Los datos son válidos y de confianza, dado que son extraídos de fuentes oficiales del ministerio de salud del gobierno de Brasil.

Tabla 12 - Supuesto 02

Código Supuesto	SU-02
Descripción	Se asume que los datos de origen presentan una distribución normal para usarlos en algoritmos de minería de datos.

CORRECCIÓN: SU-02, error ya que se supone algo que se debe comprobar.

2.4. Restricciones

Las restricciones asociadas al proyecto se muestran a continuación:

Tabla 13 - Restricción 01

Código Restricción	R-01
Descripción	El conjunto de datos debe ser utilizado ética y moralmente dado que se está manejando información delicada, de la misma forma en los resultados obtenidos se tiene que evitar la estigmatización.

Tabla 14 - Restricción 02

Código Restricción	R-02
Descripción	La disponibilidad y calidad de datos puede que no sea completa, es por esto por lo que se evaluará en la etapa de limpieza que pasarán con estos datos.

2.5. Riesgos

Los riesgos presentados en esta sección fueron realizados utilizando la metodología CRISP-DM.

2.5.1. Riesgos del Negocio

Tabla 15 - RN 01

Código Riesgo	RN-01
Descripción del riesgo	Falta de conciencia pública o de apoyo a las iniciativas de prevención del suicidio.
Gravedad	Alta

Tabla 16 - RN 02

Código Riesgo	RN-02
Descripción del riesgo	Otra organización puede lograr resultados similares en la minera de datos con antelación.
Gravedad	Media

2.5.2. Riesgos Organizacionales

Tabla 17 – RO 01

Código Riesgo	RO-01
Descripción del riesgo	Falta de coordinación y colaboración entre los diferentes departamentos u organizaciones involucradas en la prevención del suicidio.
Gravedad	Media

Tabla 18 - RO 02

Código Riesgo	RO-02
Descripción del riesgo	Financiamiento insuficiente asignado a los departamentos responsables.

Gravedad	Alta
-----------------	------

Tabla 19 - RO 03

Código Riesgo	RO-03
Descripción del riesgo	Resistencia o falta de apoyo de departamentos específicos involucrados en el proyecto.
Gravedad	Media

2.5.3. Riesgos Financieros

Tabla 20 - RF 01

Código Riesgo	RF-01
Descripción del riesgo	Incertidumbre sobre la disponibilidad de recursos financieros a largo plazo para sostener y ampliar las iniciativas de prevención del suicidio.
Gravedad	Alta

Tabla 21 - RF 02

Código Riesgo	RF-02
Descripción del riesgo	Posibles recortes presupuestarios o limitaciones financieras que pueden afectar el proyecto.
Gravedad	Alta

2.5.4. Riesgos Técnicos

Tabla 22 - RT 01

Código Riesgo	RT-01
Descripción del riesgo	Problemas de compatibilidad entre diferentes softwares o sistemas utilizados para la minería de datos
Gravedad	Baja

Tabla 23 - RT 02

Código Riesgo	RT-02
Descripción del riesgo	Desafíos en el preprocesamiento, la integración o transformación de los datos.
Gravedad	Media

Tabla 24 - RT 03

Código Riesgo	RT-03
Descripción del riesgo	Falta de recursos en el Hardware del personal para manejar el volumen o la complejidad del conjunto de datos.
Gravedad	Media

2.5.5. Riesgos relacionados a los datos y la fuente de datos

Tabla 25 - RD 01

Código Riesgo	RD-01
Descripción del riesgo	Mala calidad de los datos, como datos incompletos, inexactos o inconsistentes, que pueden afectar la confiabilidad de los resultados de la minería de datos
Gravedad	Media

Tabla 26 - RD 02

Código Riesgo	RD-02
Descripción del riesgo	Datos no confiables u obsoletos, que pueden introducir sesgos.
Gravedad	Alta

2.6. Contingencias

Para poder mitigar en parte o por completo cualquier riesgo de los ya mencionados de tal forma que no se vea afectado de manera crítica el proyecto se ha establecido un plan de actividades ante estas eventualidades el cual se exhibe a continuación:

Tabla 27 - PC 01

Código Contramedida	PC-01
Descripción de contramedida	El proyecto se realizará con un enfoque de minimización de gastos operativos, evitando el uso de software que pueda impactar negativamente en la organización. Los recursos necesarios se obtendrán de entidades externas, y se dará preferencia al uso de herramientas gratuitas disponibles.
Afecta a	RF-01, RF-02

Tabla 28 - PC 02

Código Contramedida	PC-02
Descripción de contramedida	Se realizará una revisión exhaustiva de la compatibilidad de las herramientas a utilizar en el proyecto, de modo que además se cuente con una documentación basta para no tener problemas de conocimientos con el software usado.
Afecta a	RT-01, RT-02

Tabla 29 - PC 03

Código Contramedida	PC-03
Descripción de contramedida	Para garantizar vistas minables óptimas en los análisis, los datos se someterán a un proceso de extracción, transformación y carga (ETL) específicamente diseñado para abordar la dependencia temporal de los datos.
Afecta a	RD-01, RD-02

Tabla 30 - PC 04

Código Contramedida	PC-04
Descripción de contramedida	Se generará documentación detallada sobre el progreso del proyecto, con el objetivo de facilitar la comprensión

	de los fundamentos y avances por parte del personal nuevo.
Afecta a	RO-01, RO-02, RO-03

2.7. Terminología

Para la realización de este proyecto se considera importante conocer los términos presentados a continuación para mejorar la comprensión de los análisis realizados. Sobre todo, en la parte de los códigos utilizados por la clasificación internacional de enfermedades que está directamente relacionado con el conjunto de datos utilizado.

CID: Clasificación Estadística Internacional de Enfermedades y Problemas de Salud Relacionados (ICD) es una herramienta esencial utilizada en la práctica médica y la epidemiología. Proporciona una terminología y una estructura común para clasificar y registrar enfermedades y otros problemas de salud, lo que permite el monitoreo, la comparación y el análisis de la situación de salud a nivel mundial.

En la Tabla 31 se presentan los códigos CID relacionados al suicidio, los cuales serán utilizados en las siguientes secciones del presente informe.

Tabla 31 - Códigos CID10

Código CID	Descripción
X60	Autointoxicación y exposición intencional a analgésicos, antipiréticos y antirreumáticos no opioides.
X61	Autointoxicación intencional y exposición a fármacos anticonvulsivos [antiepilépticos], sedantes, hipnóticos y psicotrópicos no clasificados en otra parte.
X62	Auto envenenamiento intencional y exposición a narcóticos y psicodislépticos [alucinógenos] no clasificados en otra parte.
X63	Autointoxicación y exposición intencionada a otras sustancias farmacológicas con acción sobre el sistema nervioso autónomo.

X64	Autointoxicación intencional y exposición a otras drogas, medicamentos y sustancias biológicas y aquellas no especificadas de otra manera.
X65	Autointoxicación voluntaria por alcohol.
X66	Autointoxicación intencional por solventes orgánicos, hidrocarburos halogenados y sus vapores.
X67	Auto envenenamiento intencional por otros gases y vapores.
X68	Auto envenenamiento intencional y exposición a pesticidas.
X69	Auto envenenamiento intencional y exposición a otros productos químicos y sustancias nocivas no especificadas.
X70	Autolesión intencional por ahorcamiento, estrangulamiento y asfixia.
X71	Autolesiones intencionales por ahogamiento y sumersión.
X72	Autolesión intencional por disparo de arma de fuego.
X73	Autolesión intencional con escopeta, rifle y armas de fuego de mayor calibre.
X74	Autolesión intencional disparando otra arma de fuego y un arma de fuego no especificada.
X75	Autolesiones intencionales con artefactos explosivos.
X76	Autolesión intencional por humo, fuego y llamas.
X77	Autolesión intencional por vapor, gases u objetos calientes.
X78	Autolesión intencional con un objeto afilado o penetrante.
X79	Autolesión intencional con objeto contundente.
X80	Autolesionarse intencionalmente al caer desde un lugar elevado.
X81	Autolesión intencional al correr o pararse frente a un objeto en movimiento.
X82	Autolesiones intencionales por impacto de un vehículo de motor.
X83	Autolesiones intencionales por otros medios especificados.
X84	Autolesionarse intencionalmente por medios no especificados.

DATASUS: Departamento de Informática del Sistema Único de Salud de Brasil. Es un departamento del Ministerio de Salud de Brasil y se encarga de recopilar, procesar y analizar datos de salud en el país.

Funasa: Fundação Nacional de Saúde (Fundación Nacional de Salud) de Brasil. Es una entidad vinculada al Ministerio de Salud de Brasil y tiene como objetivo principal promover la salud pública y mejorar las condiciones de saneamiento básico en el país.

Estados: existe también una abreviación respecto a los estados de Brasil en el dataset, en la Tabla 32 se aprecia la abreviación y su significado.

Tabla 32 - Abreviación de estados

Estado	Abreviación
São Paulo	SP
Pernambuco	PE
Rio De Janeiro	RJ
Bahia	BA
Paraíba	PB
Rio Grande Do Sul	RS
Pará	PA
Sergipe	SE
Mato Grosso Do Sul	MS
Goiás	GO
Maranhão	MA
Ceará	CE
Minas Gerais	MG
Rio Grande Do Norte	RN
Tocantins	TO
Alagoas	AL
Distrito Federal	DF
Santa Catarina	SC
Espírito Santo	ES
Paraná	PR
Piauí	PI
Mato Grosso	MT
Amazonas	AM
Rondônia	RO
Acre	AC
Amapá	AP
Roraima	RR

2.8. Especificación de costos y beneficios

Dado que la organización es de carácter gubernamental y no tiene fines de lucro en la realización de este proyecto y en su funcionamiento en general, se establece como prioridad principal la optimización de los recursos económicos disponibles. Aunque la organización cuenta con fondos aprobados para su subsistencia y apoyo a análisis, se buscará maximizar el uso eficiente de dichos recursos.

A continuación, en la Tabla 33 se presentan los gastos asociados con la ejecución de este proyecto, desglosando detalladamente los costos involucrados.

Costos de Proyecto (Inversión Inicial):

Tabla 33 - Costos de proyecto

Concepto	Valor
Software • Sistema Operativo Windows© 10 • Herramientas y plataformas: ○ Python (gratis) ○ KNIME (gratis)	\$ 100.000
Servicios • Implementación y Mantenimiento Hardware • Estudio, Implementación y Mantenimiento del proyecto • Capacitación de personal técnico y usuarios • Consultoría en procesos de negocios • Manejo de volúmenes de archivos • Generar archivos de salida accesibles para usuario	\$350.000
Hardware • Conectividad de equipos para análisis • Respaldos y mantenimiento • Equipos Cliente	\$90.000

Costo de desarrollo de Proyecto (1 mes) Tiempo invertido: 160 horas por un periodo de 1 mes (45 horas por semana -> 8 horas trabajo diario) Valor hora -> \$5.000	\$2.400.000
Gasto General • Electricidad • Materiales de Oficina • Insumos • Etc.	\$250.000
TOTAL:	\$3.190.000

A continuación, en la Tabla 34 se presentan los beneficios asociados con la ejecución de este proyecto.

Beneficios:

Tabla 34 - Beneficios

Beneficio	Valor estimado diario	Valor estimado anual
Disminución de tiempo En la realización de investigación diaria sobre la tasa de suicidios y sus efectos (proyección de ahorro de tiempo en 2 horas diarias, 5 mil pesos por hora). Ahorro • En el pago a distintos investigadores y especialistas sobre el tema. • En el costo por tiempo de aprendizaje que tomaría una capacitación para realizar un tratamiento de datos. • Pago de salarios al personal.	\$ 10.000	\$2.600.000
Identificar • Detectar de manera temprana las principales similitudes de las personas que son más propensas a cometer suicidio. Esto permitirá tomar medidas adecuadas para poder	\$0	

implementar acciones correctivas y preventivas. Identificar oportunidades para poder reducir la tasa de suicidios en Brasil y de esta forma disminuir a la vez la mortalidad.		
Varios - Combustible. - Insumos (Luz, agua, etc.) - Gastos de oficina.	\$9.000	\$2.340.000
TOTAL:	\$19.000	\$4.940.000

Evaluación del Proyecto (plazo de 3 años):

Tabla 35 - Evaluación del proyecto

Tiempo	Año 0	Año 1	Año 2	Año 3
Beneficios	\$0	\$4.940.000	\$4.940.000	\$4.940.000
Costo	\$3.190.000	\$0	\$0	\$0
Flujo	- \$3.190.000	\$4.940.000	\$4.940.000	\$4.940.000

Calcular Valor Neto Actual (indica la aceptación del proyecto)

VNA = \$ 9.095.048,84 (calculado con una tasa de interés de 10%)

Calcular Tasa de Interna de Retorno (indica la rentabilidad del proyecto)

TIR = 144,23% (el proyecto genera ganancia)

III. OBJETIVOS DE DATA MINING

3.1. Objetivos

Objetivo específico 1: Evaluar si existe una correlación significativa entre las diferentes variables que están presentes en los casos de suicidios utilizando los coeficientes de correlación de Pearson y Spearman, identificando relaciones lineales o monotónicas según los resultados.

Objetivo específico 2: Identificar patrones o grupos de variables cualitativas similares en el conjunto de datos de suicidios utilizando los algoritmos K-Modes y Fuzzy C Means para determinar si existen relaciones entre los diferentes grupos y casos de suicidio.

CORRECCIÓN: Se menciona “determinar si existen relaciones”, lo cual alude a otro tipo de problemas de DM.

3.2. Criterios de éxito

Los criterios de éxito del proyecto se establecen a continuación, cabe destacar que están directamente relacionados con los objetivos específicos planteados.

Criterio de éxito 1: Obtener de manera exitosa una descripción de cada grupo de personas que tiene una tasa de suicidio más alta o baja.

Criterio de éxito 2: Lograr detectar una correlación entre las características de las personas de manera que se pueda conseguir información adicional como una combinación de cualidades que tengan más tendencia al suicidio.

CORRECCIÓN: Mejorar redacción de ambos criterios de éxito, falta mencionar que para el criterio de éxito 1 no hay metas como cohesión y separación de grupos, para el criterio de éxito 2 falta mencionar como meta obtener correlaciones fuertes y significativas.

3.3. Plan del proyecto

CORRECCIÓN: Al mencionar una planificación, esta debe contener fechas asociadas a la realización de las actividades del proyecto.

El plan para desarrollar el proyecto consta de 6 fases en base a la metodología CRISP-DM [agregar referencia]:

1. **Comprensión del Negocio:** En esta fase inicial se comprenden objetivos y requisitos del proyecto, se define el problema de minería de datos y se elabora un plan preliminar para alcanzarlos.

2. **Entendimiento de los Datos:** En la fase de comprensión de datos, se recopilan y exploran los datos, identificando problemas de calidad y descubriendo subconjuntos relevantes para formular hipótesis sobre información oculta.
3. **Preparación de Datos:** En la fase de preparación de datos, se llevan a cabo diversas tareas, como la selección y transformación de los datos brutos iniciales, para construir el conjunto final utilizado en las herramientas de modelización.
4. **Modelamiento:** En esta etapa, se eligen y ajustan técnicas de modelización con el objetivo de obtener los mejores resultados. Diferentes técnicas pueden aplicarse según el problema, lo que puede implicar regresar a la fase de preparación de datos.
5. **Evaluación:** En esta etapa, se crea un modelo de calidad basado en el análisis de datos. Se evalúa a fondo, revisando los pasos realizados para asegurar que cumple los objetivos. Se decide el uso de los resultados obtenidos.
6. **Despliegue:** La implementación del modelo implica organizar los conocimientos adquiridos de manera utilizable para el cliente. Puede ser desde informes hasta establecer un proceso de minería de datos en toda la organización. El cliente lleva a cabo los pasos de implementación, pero debe comprender cómo utilizar los modelos creados.




Figura 1 -Metodología CRISP-DM

IV. ENTENDIMIENTO DE LOS DATOS

CORRECCIÓN: Dentro de este apartado no hay análisis de valores erróneos.

4.1. Recolección inicial de los datos

Todos los datos obtenidos fueron recopilados por el ministerio de salud de Brasil, el cual provee de manera gratuita y publica variados conjuntos de datos a través de su página web DATASUS, con información sobre morbilidad, discapacidad, accesos a los servicios, calidad de la atención, condiciones de vida y factores ambientales que se traducen en información relevante para la cuantificación y evaluación de la información en salud.

Para este conjunto de datos se descargaron solo los datos relacionados al suicidio de la base de datos DATASUS entre los años 2010 y 2019. Para seleccionar solo los casos de suicidios se tuvo en cuenta la variable “Causabas” que hace referencia a la causa subyacente de la muerte, la cual es representada mediante valores por la Clasificación Internacional de Enfermedades (CIE) entre X600 y X850. Estas gamas de casos incluyen lesiones autoinfligidas.

Tabla 36 - Detalle de la fuente de datos

Nombre del Archivo	Dados de suicidios entre 2010 e 2019
Descripción	Datos de suicidios sucedidos en Brasil considerando causas de suicidios CID-10 X60 a X84
Escala Temporal	Anual
Peso (MB)	17.23

Tabla 37 - Variables de la fuente de datos

Nombre Variable	Tipo de Variable	Descripción
abrev_estado	VarChar	Estado abreviado de Brasil donde ocurrió el suicidio
Anio	Int	Año en el que ocurrió el suicidio
mes	Int	Mes en el que ocurrió el suicidio
Circobito	VarChar	Circunstancia del suicidio
Dtobito	DateTime	Fecha del suicidio
DTnasc	DateTime	Fecha de nacimiento del individuo
Sexo	VarChar	Sexo del individuo
Racacor	VarChar	Raza del individuo
EstCiv	VarChar	Estado civil del individuo
EscMae	VarChar	Años de estudio
Ocup	VarChar	Ocupación del individuo
CodMunRes	VarChar	Municipio de residencia del individuo
LocoCor	VarChar	Lugar donde ocurrió el suicidio
AssitMed	Boolean	¿El individuo recibió asistencia médica?
Causabas	VarChar	Causa del suicidio según código CID-10
Causabas_O	VarChar	Causa del suicidio según código CID-10
Cirurgia	Boolean	¿Fue realizada una cirugía?
Estado	VarChar	Estado de Brasil donde ocurrió el suicidio
Regiao	VarChar	Región de Brasil donde ocurrió el suicidio

4.1.1. Criterios de selección

Para lograr los objetivos propuestos, se utilizarán mayormente datos cualitativos, los cuales describen información importante respecto a las personas que cometieron suicidio en Brasil. Entendiendo que los algoritmos de Datamining reciben como entrada datos números, la información contenida en el dataset será modificada en el proceso ETL con el fin de que cada característica este distinguido por un número.

Se debe también contemplar la ubicación del suicidio, aprovechando que el dataset brinda información como el Estado y Región de Brasil, esto nos puede indicar aspectos importantes respecto a tendencias de suicidio en el país, denotando aspectos como el socioeconómico y la calidad de vida de los ciudadanos.

Como atributos de fecha se cuenta con 2 principales; la fecha de nacimiento y la fecha del suicidio. Con respecto a estos datos, serán transformados en gránulos más pequeños con la finalidad de no generar posibles errores en los algoritmos de Datamining que se utilizarán para este estudio.

4.1.2. Inserción de datos

Se añadió columnas de manera estratégica que serán de utilidad para un estudio más completo y que demuestre información de forma agregada para cumplir con nuestros objetivos:

Se hizo necesario agregar los datos que denotan la región del suicidio (Figura 2), esto con la finalidad de identificar los distintos factores de cada región que tienen implicancia en los suicidios, además de generar vistas más extensas y generales respecto a la cantidad de suicidios en Brasil.



Figura 2 – Mapa de Brasil

4.2. Descripción de herramientas utilizadas

Tabla 38 - Herramientas Utilizadas

Herramienta de Software		Descripción
Plataforma:	Anaconda 2023.03	Suite de código abierto que abarca una serie de aplicaciones, librerías y conceptos diseñados para el desarrollo de la ciencia de datos con Python.
Notebook:	Jupyter Notebook	Interfaz web de código abierto que permite la inclusión de texto, video, audio e imágenes, así como la ejecución de código a través del navegador en múltiples lenguajes.
Lenguaje de programación:	Python 3.11.4	Lenguaje de programación ampliamente utilizado en la ciencia de datos, machine learning (ML) y en distintas áreas de la programación.
Librerías:	Pandas – Numpy – DateTime – Plotly	Librerías de Python dedicadas al análisis de grandes volúmenes de datos y a la creación de gráficos.

4.3. Descripción detallada de los datos

4.3.1. Formato y rango de los datos

Mediante el uso de Anaconda3, Python y la librería Pandas se realizó un análisis sobre el conjunto de datos y arrojaron los siguientes resultados para cada columna de la Tabla 39.

Tabla 39 - Detalle de los datos

Variable	Tipo	Validos	Nulos	Frecuencia absoluta	Frecuencia Relativa	Moda
Abrev_estado	Cualitativa	111437	0	27	0.000242	SP
Ano	Cualitativa	111437	0	10	8.97E-05	2019
Mes	Cualitativa	111437	0	12	0.000108	12
Dtobito	Cualitativa	111437	0	3652	0.032772	01/01/2017
Dtnasc	Cualitativa	111437	0	24663	0.221316	11/04/1984
Sexo	Cualitativo	111415	22	2	1.79E-05	Masculino
Racacor	Cualitativo	108307	3130	5	4.49E-05	Branca
Assistmed	Cualitativo	111437	0	2	1.79E-05	No
Escmae	Cualitativo	13	111424	4	3.59E-05	1 a 3 años
Estciv	Cualitativo	102825	8612	5	4.49E-05	Soltero/a
Esc	Cualitativo	83521	27916	5	4.49E-05	4 a 7 años
Ocup	Cualitativo	59741	51696	819	0.007349	Aposentado/Pensionista
Codmunres	Cualitativo	111437	0	5140	0.046124	Sao Paulo
Causabas	Cualitativo	111437	0	384	0.003446	X700
Causabas_O	Cualitativo	111152	285	636	0.005707	X700
Lococor	Cualitativo	110981	456	5	4.49E-05	Domicilio
Cirurgia	Cualitativo	111437	0	2	1.79E-05	No
Estado	Cualitativo	111437	0	27	0.000242	Sao Paulo
Regiao	Cualitativo	111437	0	5	4.49E-05	Sudeste

Como se aprecia en la Tabla 39 los datos en su totalidad son válidos para realizar un análisis, a excepción de la columna EscMae la cual cuenta con 111.424 datos nulos y la columna Ocup la cual cuenta con 51.696 datos nulos.

4.3.2. Comprensión de los atributos en términos del negocio

La fuente de datos original representa información respecto a suicidios identificados en Brasil entre los años 2010 al 2019. Cabe destacar, que cada fila contiene información como la fecha de nacimiento, fecha de defunción, escolaridad, si existió cirugía, raza, etc.

Como es de notar, toda la información es cualitativa, ya que son características de las personas afectadas. Unas de las acciones que se equipara con nuestros objetivos es transformar toda la información en tuplas que identifiquen nuestras variables.

Esta información nos ayudara a determinar patrones en función de los suicidios, siendo una parte fundamental ir correlacionando atributos para identificar datos que sean un aporte para, finalmente, ayudar a predecir posibles factores que aumenten la cantidad de suicidios. Es por esto, que también se agregó la columna de Región, lo cual nos puede proveer información crucial que sea de utilidad para el Ministerio de salud de Brasil, con la finalidad de generar mejores campañas para prevenir el suicidio y atacar esta problemática de manera temprana en virtud de la población brasileña.

4.3.3. Estadísticos descriptivos

Para conocer el comportamiento del conjunto de datos se consideró necesario realizar un análisis en la distribución y frecuencia de las categorías, principalmente porque el conjunto de datos solo contiene variables categóricas.




Figura 3 - Distribución de abrev_estado

En la Figura 3 se puede ver la distribución de los datos presentes en la columna abrev_estado, en esta columna se encuentra la abreviación de los estados de Brasil. Como se puede ver SP es el estado con más incidencias de suicidios y RR el que menor presenta.




Figura 4 - Distribución de Sexo

En la Figura 4 se muestra la distribución del sexo de las personas que han cometido suicidio durante los años 2010 a 2019. Se observa una clara diferencia en las incidencias entre los hombres y mujeres.

En el caso de los hombres, se registra un número significativamente mayor de suicidios, superando las 80.000 incidencias. Esto indica que los hombres presentan una mayor propensión al suicidio en comparación con las mujeres durante este período.

Sin embargo, se observa que las mujeres también han experimentado un número considerable de casos de suicidio, con una cifra que sitúa entre 20.000 y 40.000. Aunque la cantidad es menor en comparación con los hombres, es importante tener en cuenta que el suicidio femenino sigue siendo una preocupación.




Figura 5 - Distribución de Raza

En la Figura 5 se puede ver la distribución de las razas que han cometido suicidio durante los años 2010 a 2019 en Brasil. Se observan 5 categorías raciales Branca (Blanca), Amarela (Amarilla), Parda (Mestiza), Preta (Negra) e Indígena.

Se muestra que la raza con mayor incidencia de suicidios es la Blanca superando las 50.000. Esta categoría racial tiene la mayor proporción de casos de suicidios en el conjunto de datos. Por otro lado, la raza Amarilla muestra la menor cantidad de suicidios en el periodo analizado.

Es importante considerar que este análisis no define que raza tiene mayor o menor importancia en base a su cantidad de incidencias, cada una de ellas es relevante y merece una atención adecuada.




Figura 6 - Distribución de AssistMed

Como se puede apreciar en la Figura 6, existe una frecuencia sumamente alta de personas que cometieron suicidio que no recibieron algún tipo de asistencia médica, mientras que la minoría, con una frecuencia menor a 20.000 existencias si recibieron algún tipo de asistencia.

La asistencia médica es un factor sumamente importante y que puede hacer la diferencia con personas en riesgo de suicidio, en especial si cuentan con alguna enfermedad mental o problemas de abuso de sustancias, ya que se pueden beneficiar con tomar medicamentos y al mismo tiempo reciben una intervención psicosocial.

Los medicamentos pueden beneficiar a algunas personas en riesgo de suicidio y los proveedores de atención médica y los pacientes pueden colaborar entre sí para encontrar el mejor medicamento, o una combinación de estos, así como la dosis adecuada.




Figura 7 - Distribución de EstCiv

De acuerdo con la Figura 7, la población que más suicidios comete según su estado civil son los solteros, estos cuentan con una frecuencia de por sobre las 50.000 incidencias en el conjunto de datos. Esto indica que las personas solteras tienen una propensión más alta al suicidio en comparación a las otras categorías del estado civil durante el periodo de 2010 a 2019.

La siguiente categoría con mayor número de suicidios es de las personas casadas, con al menos 30.000 incidencias. Aunque su cifra es inferior a la de las personas solteras, aún representa una proporción significativa de los suicidios registrados.




Figura 8 - Distribución de LocoCor

La Figura 8 muestra la distribución de las locaciones donde las personas han cometido suicidio durante el periodo de 2010 a 2019. Se identifican categorías como Domicilio, Otros (otras localidades), Hospital donde generalmente llegan personas que han sido trasladadas y lamentablemente fallecen en este establecimiento, la vía pública y otros establecimientos de salud.

La locación con mayor número de suicidios es el domicilio, con más de 60.000 incidencias. Esto indica que la mayoría de las personas que han cometido suicidio lo han hecho en sus propios hogares.

El hospital se presenta como la segunda locación con mayor número de suicidios, con cerca de 20.000 incidencias. Es importante destacar que estos casos pueden corresponder a personas que han cometido suicidio mientras se encontraban en un entorno hospitalario o que

han sido trasladadas tras haber cometido un intento de suicidio y han perdido la vida al llegar a este establecimiento.




Figura 9 - Evolución casos de suicidios a través de los años

Teniendo en cuenta que nuestros datos comienzan desde el 2010, se puede apreciar en la Figura 9 un aumento en los casos de suicidio en Brasil a lo largo de los años, lo cual es sumamente preocupante y deja ver que las campañas de prevención del suicidio no han resultado como se espera.




Figura 10 - Relación entre estado civil y asistencia médica

La Figura 10 demuestra la relación que existe entre si la persona recibió asistencia médica y su estado civil. Se puede apreciar que, de las personas que no recibieron asistencia médica la gran mayoría corresponde a solteros, seguido de casados, separado judicialmente y viudo. En el caso de las personas que, si recibieron asistencia médica, también se puede ver la alta presencia de personas solteras y casados.




Figura 11 - Relación entre asistencia médica y raza del individuo

La Figura 11 demuestra la relación que existe entre si la persona recibió asistencia médica y su raza. Se puede apreciar que, de las personas que no recibieron asistencia médica la gran mayoría corresponde a raza ‘parda’, seguido de ‘branca’.

En el caso de las personas que, si recibieron asistencia médica, este sigue el mismo patrón.

Debido a que se cuenta con solamente datos cualitativos, es que es necesario este análisis de contenido con la finalidad de identificar en primera medida las palabras más frecuentes en columnas que pueden llegar a darnos información importante respecto a los suicidios en Brasil. Esta información se presenta en la Tabla 40.

Tabla 40 - Frecuencia de palabras por columna

OCUP	CAUSABAS	CAUSABAS_O
Aposentado/Pensionista	X700	X700
Estudiante	X709	X709

Geral	X740	X740
Trabalhador	X708	X708
Agropecuário	X704	R99
Dona	X680	Y200
Casa	X689	X704
Servicos	X800	Y349

4.3.4. Calidad de los datos

Como era de esperarse en los SU-01 y SU-02, el conjunto de datos posee una calidad de datos apropiada gracias al análisis realizado, por lo que, de ser necesario el uso de herramientas para mejorar la calidad de estos, sería necesariamente para acotarse a las exigencias de los algoritmos que manejan las herramientas de DM.

V. PREPARACIÓN DE DATOS

CORRECCIÓN: No hay normalización de datos para el modelo Fuzzy CMeans, lo cual pudo haber afectado los resultados de implementación y despliegue del modelo.

En esta etapa se modifican los tipos de datos para cada algoritmo que se desea utilizar. Como resultado de este proceso se generan estructuras de datos las que de ahora en adelante serán referidas como vistas minables.

En esta etapa se realizaron iteraciones para volver a cambiar las vistas minables construidas y adaptarlas a los requerimientos de los algoritmos utilizados.

5.1. Transformación de datos

La Figura muestra el proceso de transformación del conjunto de datos de suicidios en Brasil en los años 2010 a 2019 para luego poder ser analizados por los algoritmos que se utilizarán más adelante.




Figura 12 - Transformación de datos en Knime 1

En la Figura 12 se muestra el comienzo del proceso de transformación de datos utilizando la herramienta Knime.

El proceso comienza leyendo el CSV correspondiente al conjunto de datos de suicidios en Brasil en los años 2010 a 2019, continúa seleccionando las columnas que serán utilizadas en los algoritmos las cuales serán Racacor (Raza), EstCiv (Estado Civil), Regiao (Región), Sexo, LocoCor (Ubicación donde ocurrió el incidente) y Estado (Estado de Brasil). El proceso continúa eliminando los posibles valores nulos, y luego comienza a realizar el reemplazo de datos para la variable Raza en los que se le asignará a cada raza existente un número específico.




Figura 13 - Transformación de datos en Knime 2

En la Figura 13 se muestra la continuación de este proceso de reemplazo de datos para cada una de las columnas mencionadas anteriormente, en donde a cada valor cualitativo se le asignará un número respectivo.

5.2. Selección de datos

Para este proyecto se han seleccionado aquellos datos dentro del dataset que caracterizan a las personas que cometieron suicidio. Esta elección se ha hecho en base a los objetivos de minería de datos de forma que vayan enlazados netamente con estos los propósitos ya descritos previamente. Por el contrario, las demás columnas que ofrecen datos temporales de nacimiento y deceso, si recibió asistencia médica y si tuvo cirugía no aportan a proporcionar una descripción del sujeto. Por otro lado, columnas como la ocupación, años de estudio, municipio, si bien pueden formar parte de la selección, lamentablemente la cantidad de registros nulos impide llevar a cabo su consideración.

5.3. Limpieza de datos

Al tener en cuenta los datos que ingresarán al proceso de Data Mining queda realizar una limpieza para modificar o eliminar determinados registros que en nuestro caso cuentan con datos faltantes los cuales se descartaron. Por otra parte, se transformaron los datos a valores numéricos ordinales por ejemplo dentro de la columna que indica el sexo del sujeto, se reemplazan los valores Femenino y Masculino por 1 y 0 respectivamente, de la misma forma para todas las columnas seleccionadas, esto se hace para que sea aceptado por los algoritmos de Clustering y de correlación que se utilizarán más adelante. Cabe destacar que el conjunto de datos inicial para los atributos escogidos era de buena calidad, es decir no había datos erróneos o atípicos salvo claramente que no existiera dicho dato.

5.4. Integración de datos

Los datos al ser de buena calidad, permite que no se realicen más transformaciones de datos más allá de los requeridos para aplicar las técnicas de minería de datos. Al ser datos cualitativos en su completitud, no se pueden generar variables derivadas desde las existentes, por ende, una vez terminada la última transformación a número ordinal se obtiene la vista minable deseada que será trabajada. (Véase Figura 14)

▲ Table with replaced column - 3:25 - Cell Replacer (Reemplazo de Datos)

File Edit Hilite Navigation View

Table "default" - Rows: 100352 Spec - Columns: 6 Properties Flow Variables						
Row ID	S SEXO	S RACACOR	S ESTCIV	S LOCOCOR	S estado	S regioao
Row0	0	1	2	0	25	3
Row1	0	0	0	0	25	3
Row2	0	1	4	0	25	3
Row3	0	1	4	0	25	3
Row4	0	0	0	0	25	3
Row5	0	1	0	0	25	3
Row6	0	1	4	0	25	3
Row7	0	1	4	0	25	3
Row8	0	1	2	0	25	3
Row9	0	1	0	0	25	3
Row10	0	3	2	0	25	3
Row11	0	0	4	0	25	3
Row12	0	1	4	0	25	3
Row14	0	1	4	3	25	3
Row15	0	1	4	1	25	3
Row16	0	1	4	0	25	3
Row17	0	1	2	0	25	3
Row18	1	1	4	0	25	3
Row19	1	0	4	1	25	3
Row20	0	0	0	1	25	3
Row21	0	0	0	0	25	3
Row23	0	1	4	4	25	3
Row24	0	1	0	0	25	3
Row25	0	0	4	0	25	3
Row26	0	1	1	0	25	3
Row27	0	1	0	0	25	3
Row28	0	3	4	4	25	3
Row29	0	1	0	0	25	3
Row30	0	1	4	0	25	3
Row31	0	1	4	1	25	3
Row32	0	1	0	1	25	3
Row33	1	1	0	3	25	3
Row34	1	0	4	0	25	3
Row35	0	1	0	1	25	3
Row36	0	1	4	1	25	3
Row37	0	3	0	0	25	3
Row38	1	3	0	1	25	3
Row39	0	1	4	0	25	3

Figura 14 - Vista minable

VI. MODELAMIENTO

6.1. Selección de técnicas de modelamiento

6.1.1. Segmentación (Clustering)

Esta técnica de modelamiento es un método usado para segmentar un conjunto de datos, en el caso de este proyecto, se segmenta en subgrupos que comparten características comunes entre sí a diferencia de los otros subgrupos que se formen.

La meta principal del Clustering es descubrir patrones en el conjunto de datos dado sin tener información previa sobre este mismo.

Dado el conjunto de datos en el que se está trabajando para este proyecto y en conjunto con uno de los objetivos planteados, esta técnica es perfecta para poder identificar distintos grupos de personas con rasgos en común para así crear un perfil de estas.

6.1.1.1. Algoritmo K-Modes

El algoritmo K-Modes es un algoritmo de agrupamiento utilizado para agrupar datos categóricos. La idea principal detrás de este algoritmo es agrupar instancias de datos en grupos basados en la similitud de sus características. El algoritmo utiliza la distancia de Hamming para calcular la similitud entre instancias de datos, esta se calcula como el número de características diferentes entre las instancias.

Para este proyecto, este algoritmo fue utilizado como una variante del algoritmo K-Means debido a que nuestro conjunto de datos cuenta solamente con variables cualitativas.

Una vez que el algoritmo converge, los grupos finales se determinan por los centroides finales y las instancias asignadas a cada grupo.

6.1.1.2. Algoritmo Fuzzy C-Means

El algoritmo Fuzzy C-Means es una técnica utilizada en inteligencia artificial y sistemas de control para manejar la incertidumbre y la imprecisión en los datos. A diferencia de la lógica booleana tradicional que maneja valores de True o False, esta lógica difusa permite la representación y el razonamiento sobre la información donde los valores pueden estar en un rango continuo entre verdadero y falso.

Este algoritmo utiliza conjuntos difusos, que son conjuntos en los que los elementos tienen grados de pertenencia en lugar de una pertenencia binaria. Estos grados de pertenencia tienen asignado un valor entre 0 y 1 a cada elemento en función de su grado de pertenencia al conjunto.

6.1.2. Coeficientes de Correlación

Los coeficientes de correlación son herramientas estadísticas empleadas para analizar la relación entre dos variables. Los valores provenientes de estas medidas indican la magnitud de asociación entre dos variables, es decir, si hay una relación entre ellas. Estos coeficientes varían sus valores entre -1, que indica una correlación negativa perfecta, hasta 1 que significa que hay una correlación positiva perfecta, también puede ser 0, lo que señalaría una inexistencia de correlación.

Con estas correlaciones se pretende visualizar patrones sobre las cualidades que tuvo la persona que decidió quitarse la vida, esto va en ayuda a cumplir uno de los objetivos planteados para el proyecto.

6.2. Generación diseño de prueba

Para los casos de análisis mediante agrupación se tuvo en consideración la elección de algoritmos especialmente adecuados para variables categóricas como lo son K-Modes y Fuzzy C-Means. En relación con el punto 4 del informe, que aborda el entendimiento de los datos, se presentaron las frecuencias de las diferentes variables cualitativas lo que nos permitió seleccionar las variables relevantes y conocer si existe un desequilibrio en los datos antes de ser utilizados en los algoritmos de agrupación.

El análisis de correlación no requiere una partición de datos para entrenamiento y pruebas, ya que no implica ningún tipo de entrenamiento. Al trabajar con el conjunto completo de datos, se desea obtener una visión general de las relaciones entre las variables. Además, para validar la significancia de los coeficientes de correlación, se utilizan pruebas de hipótesis específicas para correlaciones, lo que elimina la necesidad de una partición adicional para realizar pruebas.

6.3. Construcción de los modelos

6.3.1. Configuración de parámetros

6.3.1.1. Clustering

Para los algoritmos de segmentación se han seleccionado las mismas columnas que se seleccionaron previamente, esto debido a que son todas las que están relacionadas al objetivo de este proyecto que busca idear un perfil de la persona que cometió suicidio. (Véase Figura 15)

```
# Seleccionar las columnas relevantes para el clustering
columnas = ['SEXO', 'RACACOR', 'ESTCIV', 'LOCOCOR', 'estado', 'regiao']
```

Figura 15 - Columnas seleccionadas para Clustering

Por otro lado, si bien para estos algoritmos es necesario la normalización, dado la naturaleza del conjunto de datos que en su completitud maneja atributos cualitativos, será prescindible este preprocesamiento.

```
# Crear una instancia del algoritmo K-Modes
kmodes = KModes(n_clusters=3, init='Huang', n_init=20, verbose=1)
```

Figura 16 - Clústeres utilizados

Para terminar con esta configuración de parámetros se dejó el número de clústeres en 3, en esto se basó en el método del “codo” para la mejor opción. (Véase Figura 17)




Figura 17 - Método del Codo

Además, se determinaron que el valor de `init` que se refiere al método para seleccionar los centroides iniciales de los grupos, el cual se estableció en `Huang` dado que sirve mejor para datos grandes por su simpleza y rapidez, este método se basa en una estrategia heurística para definir centroides de manera equitativa. Luego se tiene el parámetro `n_init` que se dejó en 20 ya que determinamos que es una cantidad prudente de veces que se ejecuta el algoritmo para obtener el mejor resultado. Finalmente, el valor de `verbose` se dejó en 1 para ir viendo cuales eran las salidas al momento de ejecución este parámetro no influye directamente en el algoritmo.

Para el caso del algoritmo Fuzzy C-Means se definen los parámetros mostrados en la Figura 18.

```
# Ajusta los parámetros del algoritmo FCM
fcm = fuzz.cluster.cmeans(data_numeric.T, n_clusters, 2, error=0.005, maxiter=1000)
```

Figura 18 - Parámetros Fuzzy C-Means

En donde `data_numeric.T` vienen siendo los datos numéricos que se necesitarán para el agrupamiento, `n_clusters` será la cantidad de clústeres definidos, el valor 2 indica la convergencia del punto hacia un clúster, en este caso este parámetro indica que un punto pertenecerá a un solo grupo. Luego tenemos el error, que viene siendo la precisión de la convergencia hacia un grupo, en donde se establece esta variable con el valor 0.005 para tener una mejor exactitud de la asignación dada. Para terminar, el dato `maxiter` que corresponde a las iteraciones del algoritmo tendrá el valor 1000 dado que es una cantidad razonable para el conjunto de datos y columnas dadas.




Figura 19 – Método del Codo para Fuzzy C-Means

6.3.1.2. Coeficientes de Correlación

Para realizar los algoritmos de coeficientes de correlación como Pearson y Spearman, es necesario realizar antes una prueba estadística llamada Test de Chi-Cuadrado, la cual, se utiliza principalmente para evaluar si existe una asociación significativa entre las variables categóricas.

```

In [8]: 1 import pandas as pd
        2 from scipy.stats import chi2_contingency
        3
        4 # Leer el archivo CSV (u otro formato) con el dataset
        5 dataset = pd.read_csv('suicidios.csv')
        6
        7 # Seleccionar las 6 columnas categóricas del dataset
        8 columnas = ['SEXO', 'RACACOR', 'ESTCIV', 'LOCOCOR', 'estado', 'regiao']
        9 datos = dataset[columnas]
        10
        11 # Realizar el test de chi cuadrado
        12 statistic, p_value, degrees_of_freedom, expected = chi2_contingency(datos)
        13
        14 # Imprimir los resultados
        15 print("Estadístico de prueba:", statistic)
        16 print("Valor p:", p_value)
        17 print("Grados de libertad:", degrees_of_freedom)
        18 print("Frecuencias esperadas:")
        19 print(expected)
        20

```

Figura 20 - Código Test de Chi-Cuadrado

Se utilizó el código presentado en la Figura 19 para realizar la prueba de Chi-Cuadrado en las columnas del conjunto de datos que serán introducidas en los algoritmos, donde nos arrojó los siguientes valores:

Tabla 41 - Resultados Chi-Cuadrado

Estadísticos de prueba	643941.1661057961
Valor p	0.0
Grados de Libertad	501755

Las frecuencias esperadas para cada columna y dato que será utilizado se presentan en la Figura 20.

```

Frecuencias esperadas:
[[ 0.29364315  2.71427499  2.00730771  1.21086374 21.45587405  3.31803636]
 [ 0.26522607  2.45160322  1.81305213  1.09368338 19.37949914  2.99693607]
 [ 0.31258787  2.88938951  2.13681143  1.28898398 22.84012399  3.53210322]
 ...
 [ 0.26522607  2.45160322  1.81305213  1.09368338 19.37949914  2.99693607]
 [ 0.27469843  2.53916048  1.87780399  1.1327435  20.07162411  3.1039695 ]
 [ 0.27469843  2.53916048  1.87780399  1.1327435  20.07162411  3.1039695 ]]

```

Figura 21 - Frecuencias esperadas Test de Chi-Cuadrado

Dado los resultados, y bajo las siguientes hipótesis:

- $H_0: p > 0.05 \rightarrow$ No existe asociación entre las variables categóricas.

- $H1: p < 0.05 \rightarrow$ Existe una asociación entre las variables categóricas.

Podemos concluir de los resultados que existe una asociación altamente significativa entre las variables categóricas, ya que, el valor p es muy cercano a 0. Esto indica que las variables categóricas no son independientes entre sí y están relacionadas de alguna manera, lo que nos permite seguir adelante con el análisis de correlaciones.

6.3.2. Modelos

6.3.2.1. Clustering

Para el análisis de agrupación, se utilizó la herramienta Knime Analytics Platform que es esencial para minería de datos por su amplia variedad de aplicaciones, además de proporcionar un entorno visual para el desarrollo de flujos de trabajo de análisis de datos, lo que facilitó la construcción y ejecución de las tareas de Clustering.

Los modelos construidos serán basados en dos algoritmos de Clustering no jerárquicos llamados K-Modes y Fuzzy C-Means. Para cada uno de estos se evaluó el método del “codo” para encontrar un equilibrio entre la cantidad de clústeres.

Para cada algoritmo se utilizó en Knime un espacio de trabajo donde se trabaja el conjunto de datos reemplazados los datos cualitativos por datos numéricos representativos para cada atributo. (Véase Figura 21)




Figura 22 - Flujo de trabajo en Knime para algoritmos de Clustering

Luego se utiliza el módulo llamado Python Script para generar un código en Python donde se utilizan librerías como Knime.scripting.io y skfuzzy para llevar a cabo estos algoritmos. (Véase Figura 22)




Figura 23 - Flujo de trabajo en Knime para algoritmos de Clustering paso final

6.3.2.2. Coeficientes de Correlación

Para cuantificar las relaciones o asociaciones entre las variables con las que cuenta el conjunto de datos trabajado en el presente informe, se utilizó dos tipos de coeficientes de correlación para determinar existencias de relaciones lineales y para medir la fuerza y dirección de dicha relación: Coeficiente de Correlación de Pearson y Coeficiente de Correlación de Spearman.

Estos coeficientes son calculados utilizando el lenguaje de programación Python en un entorno de Jupyter de Anaconda en donde se utiliza, Scypi para realizar cálculos científicos, en nuestro caso, para estadística.

Se usará la función ‘pearsonr’ y ‘spearmanr’ (ver Anexo 10.1), las cuales forman parte del submódulo ‘scipy.stats’, utilizadas para calcular el Coeficiente de Correlación de Pearson y de Spearman entre diversos conjuntos de datos. También, de esta librería será utilizada la función ‘chi2_contingency’ (ver Anexo 10.2), la cual sirve para realizar la prueba de independencia de chi-cuadrado en tablas de contingencia.

6.3.3. Visualización de modelos

6.3.3.1. Clustering

A continuación, se presenta el script utilizado para el algoritmo K-Modes (Figura 23), este algoritmo fue insertado dentro del nodo Python Script proporcionado por la herramienta Knime Analytics Platform.

▲ Dialog - 3:49 - Python Script (K-Modes)

File

Script Executable Selection Templates Flow Variables Job Manager Selection Memory Policy

Input variables

knio.input_tables[0]

- SEXO
- RACACOR
- ESTCIV
- LOCOCOR
- estado
- regiao

Flow variables

knime.workspace

```
1 import knime.scripting.io as knio
2 import matplotlib.pyplot as plt
3 from kmodes.kmodes import KModes
4 # This example script simply outputs the node's input table.
5
6 knio.output_tables[0] = knio.input_tables[0]
7 pd = knio.input_tables[0].to_pandas()
8
9 knio.output_tables[0] = knio.Table.from_pandas(pd)
10
11 # Cargar los datos
12 data = pd
13 # Seleccionar las columnas relevantes para el clustering
14 columnas = ['SEXO', 'RACACOR', 'ESTCIV', 'LOCOCOR', 'estado', 'regiao']
15
16 # Preparar los datos para el algoritmo de clustering
17 X = data[columnas]
18
19 # Crear una instancia del algoritmo K-Modes
20 kmodes = KModes(n_clusters=3, init='Huang', n_init=5, verbose=1)
21
22 # Aplicar el algoritmo a los datos
23 clusters = kmodes.fit_predict(X)
24
25 # Agregar las etiquetas de los clusters al conjunto de datos original
26 data['cluster'] = clusters
27
28 # Imprimir los resultados
29 print(data[['SEXO', 'RACACOR', 'ESTCIV', 'LOCOCOR', 'estado', 'regiao', 'cluster']])
30 data['cluster'] = data['cluster'].astype(int)
31 output_table = knio.Table.from_pandas(pd)
32 knio.output_tables[0] = output_table
```

Figura 24 - Script Algoritmo K-Modes

Al ejecutar el script, este obtiene en primera instancia la vista minable como archivo CSV, luego se seleccionan las columnas relevantes para el Clustering. Finalmente, se selecciona el número de clústeres que se generarán, calculados previamente por el método del “codo” y gracias a las librerías Knimes.scripting.io, matplotlib.pyplot y kmodes.kmodes se generan los clústeres de K-Modes. (Véase Figura 24)

48

Table - 3:49 - Python Script (K-Modes)

File Edit Hilite Navigation View

Table "default" - Rows: 100352 Spec - Columns: 7 Properties Flow Variables

Row ID	SEXO	RACAC...	ESTCIV	LOCOC...	estado	regiao	cluster
Row0	0	1	2	0	25	3	2
Row1	0	0	0	0	25	3	2
Row2	0	1	4	0	25	3	2
Row3	0	1	4	0	25	3	2
Row4	0	0	0	0	25	3	2
Row5	0	1	0	0	25	3	2
Row6	0	1	4	0	25	3	2
Row7	0	1	4	0	25	3	2
Row8	0	1	2	0	25	3	2
Row9	0	1	0	0	25	3	2
Row10	0	3	2	0	25	3	2
Row11	0	0	4	0	25	3	2
Row12	0	1	4	0	25	3	2
Row14	0	1	4	3	25	3	2
Row15	0	1	4	1	25	3	2
Row16	0	1	4	0	25	3	2
Row17	0	1	2	0	25	3	2
Row18	1	1	4	0	25	3	2
Row19	1	0	4	1	25	3	2
Row20	0	0	0	1	25	3	2
Row21	0	0	0	0	25	3	2
Row23	0	1	4	4	25	3	2
Row24	0	1	0	0	25	3	2
Row25	0	0	4	0	25	3	2
Row26	0	1	1	0	25	3	2
Row27	0	1	0	0	25	3	2
Row28	0	3	4	4	25	3	2
Row29	0	1	0	0	25	3	2
Row30	0	1	4	0	25	3	2
Row31	0	1	4	1	25	3	2
Row32	0	1	0	1	25	3	2
Row33	1	1	0	3	25	3	2
Row34	1	0	4	0	25	3	2
Row35	0	1	0	1	25	3	2
Row36	0	1	4	1	25	3	2
Row37	0	3	0	0	25	3	2

Figura 25 - Clústeres de K-Modes

De igual manera se presenta en la Figura 25 el script generado para el algoritmo Fuzzy C-Means, el cual siguió el mismo proceso de inserción dentro del nodo Python Script en la herramienta Knime Analytics Platform.

File

Script Executable Selection Templates Flow Variables Job Manager Selection Memory Policy

Input variables

- knio.input_tables[0]
 - SEXO
 - RACACOR
 - ESTCIV
 - LOCOCOR
 - estado
 - regiao

Flow variables

- knime.workspace

```

1 import knime.scripting.io as knio
2 import pandas as pd
3 import numpy as np
4 import skfuzzy as fuzz
5
6 # This example script simply outputs the node's input table.
7
8 knio.output_tables[0] = knio.input_tables[0]
9 pd = knio.input_tables[0].to_pandas()
10
11 knio.output_tables[0] = knio.Table.from_pandas(pd)
12
13 # Cargar los datos
14 data = pd
15 # Selecciona las columnas que contienen las variables numéricas ordinales
16 columns = ['ESTCIV', 'SEXO', 'RACACOR', 'LOCOCOR', 'estado', 'regiao']
17 data_numeric = data[columns].values
18
19 # Define el número de clusters
20 n_clusters = 3
21
22 # Ajusta los parámetros del algoritmo FCM
23 fcm = fuzz.cluster.cmeans(data_numeric.T, n_clusters, 2, error=0.005, maxiter=1000)
24
25 # Obtiene los resultados del clustering
26 cluster_membership = np.argmax(fcm[1], axis=0)
27
28 # Agrega los resultados al DataFrame original
29 data['Cluster'] = cluster_membership
30
31 data['Cluster'] = data['Cluster'].astype(int)
32
33 output_table = knio.Table.from_pandas(pd)
34 knio.output_tables[0] = output_table
    
```

Figura 26 - Script Algoritmo Fuzzy C-Means

Al ejecutar el script, este obtiene en primera instancia la vista minable como archivo CSV, luego se seleccionan las columnas relevantes para el Clustering. Finalmente, se selecciona el número de clústeres que se generarán, y gracias a las librerías Knimes.scripting.io, numpy y skfuzzy se generan los clústeres del algoritmo Fuzzy C-Means. (Véase Figura 26)

File Edit Hilite Navigation View

Table "default" - Rows: 100352 Spec - Columns: 7 Properties Flow Variables

Row ID	SEXO	RACAC...	ESTCIV	LOCOC...	estado	regiao	Cluster
Row0	0	1	2	0	25	3	2
Row1	0	0	0	0	25	3	2
Row2	0	1	4	0	25	3	2
Row3	0	1	4	0	25	3	2
Row4	0	0	0	0	25	3	2
Row5	0	1	0	0	25	3	2
Row6	0	1	4	0	25	3	2
Row7	0	1	4	0	25	3	2
Row8	0	1	2	0	25	3	2
Row9	0	1	0	0	25	3	2
Row10	0	3	2	0	25	3	2
Row11	0	0	4	0	25	3	2
Row12	0	1	4	0	25	3	2
Row14	0	1	4	3	25	3	2
Row15	0	1	4	1	25	3	2
Row16	0	1	4	0	25	3	2

Figura 27 - Clústeres Fuzzy C-Means

6.3.3.2. Coeficientes de Correlación

El script de Python presentando en la Figura 27, corresponde al cálculo de correlación de Spearman, en donde en primera instancia recibe la vista minable como archivo CSV, luego y seleccionando las columnas deseadas para no generar errores, es que se generan los coeficientes de correlación para cada elemento a analizar.




Figura 28 - Script Spearman

Al ejecutar el algoritmo se obtiene la matriz de correlaciones de Spearman presentada en la Tabla 42.

Tabla 42 - Matriz de Spearman

	Sexo	Raza	Estado Civil	Ubicación	Estado	Región
Sexo	1	-0,04884214	0,014508616	-0,002911576	0,006239525	0,000508217
Raza	-0,04884214	1	0,128141715	0,034320024	-0,338289185	-0,467261265
E. Civil	0,014508616	0,128141715	1	-0,005512044	-0,051090253	-0,089929564
Ubicación	-0,002911576	0,034320024	-0,005512044	1	-0,015979849	-0,02173254
Estado	0,006239525	-0,338289185	-0,051090253	-0,015979849	1	0,510827985
Región	0,000508217	-0,467261265	-0,089929564	-0,02173254	0,510827985	1

De igual forma, se sigue el proceso anterior para generar los coeficientes de correlación de Pearson. (Véase Figura 28)




Figura 29 - Script Pearson

Finalmente, se obtiene la matriz de correlación presenta en la Tabla 43.

Tabla 43 - Matriz de Pearson

	Sexo	Raza	Estado Civil	Ubicación	Estado	Región
Sexo	1	-0,048939515	0,026686081	-0,05551577	0,00779894	0,00184217
Raza	-0,048939515	1	0,111014147	0,03366032	-0,3434814	-0,4452136
E. Civil	0,026686081	0,111014147	1	-0,00976645	-0,0458195	-0,07395742
Ubicación	-0,055515767	0,03366032	-0,009766454	1	-0,0220114	-0,01731938
Estado	0,007798943	-0,343481434	-0,045819532	-0,02201144	1	0,54711633
Región	0,001842172	-0,445213603	-0,073957417	-0,01731938	0,54711633	1

6.4. Patrones obtenidos

Dada la naturalidad de los algoritmos utilizados, los patrones obtenidos serán presentados en el Punto 8 del presente informe, que corresponde a la etapa del despliegue.

VII. EVALUACIÓN

7.1. Evaluación de resultados

7.1.1. Descripción de métodos de validación

Para la técnica de clustering se van a emplear dos métodos de validación para así corroborar en este caso el número de clústeres que tiene que dar como salida el algoritmo.

En el caso del algoritmo K-Modes se aplicó el método de codo (SSE) y el coeficiente de silueta promedio (*silhouette_score*).

En tanto para el algoritmo Fuzzy C-Means se aplicará el mismo método del codo en base al grado de pertenencia y de igual forma se empleará el coeficiente de silueta.

A continuación se describen estos métodos:

Método del Codo (SSE): En este caso se calcula la suma de errores cuadrados (SSE) en donde se utiliza el valor cost que se refiere a la suma de las distancias al cuadrado entre cada punto de datos y su centroide correspondiente dentro del clúster. Cuanto menor sea el costo, mejor se ajustarán los puntos de datos a sus respectivos clústeres.

Método de la Silueta (*silhouette_score*): Este método de igual forma que los explicados anteriormente, busca medir la calidad de un Clustering, y en particular este procedimiento se basa en otorgar un número entre 1 y -1 que indica qué tan bien está asignado el dato a un clúster, donde 1 es que está correctamente asignado y -1 que no lo está. El coeficiente de silueta se basa en la distancia promedio al clúster al que pertenece y la distancia promedio a los clústeres vecinos más cercanos.

En el caso de los coeficientes de correlación, se utilizó la prueba del Chi-Cuadrado, la cual, determina si hay una asociación significativa entre dos variables categóricas al comparar bajo una hipótesis nula de independencia. Esta prueba consta del siguiente esquema y se realiza para cada uno de los p valores en la Tabla 42.

1	Plantear Hipótesis: ¿Existe correlación entre las variables? H0: No existe asociación entre las variables categóricas. H1: Existe una asociación entre las variables categóricas.
2	Establecer el nivel de significancia Nivel de Significancia: $\alpha = \alpha \% = \alpha/100$
3	Seleccionar estadísticos de prueba • Correlación de Pearson • Correlación de Spearman
4	Lectura del Valor P
5	Establecer una hipótesis como aceptada

7.1.2. Validación y comparación de resultados

Para poder corroborar que los análisis realizados son válidos, es necesario evaluar mediante las pruebas y teorías mencionadas en los anteriores puntos del presente informe. En esta etapa se detalla dicha validación.

En el caso de las correlaciones, se consideraron evaluar las correlaciones las cuales su valor P es mayor 0, debido a que estas automáticamente aprueban la H0 o Hipótesis nula mencionada en la Tabla 43.

Tabla 45 - Prueba de hipótesis

1	Plantear Hipótesis: ¿Existe correlación entre las variables? H0: No existe asociación entre las variables categóricas. ($P > 0.05$) H1: Existe una asociación entre las variables categóricas. ($P < 0.05$)
2	Establecer el nivel de significancia Nivel de Significancia: $\alpha = 5\% = 0.05$
3	Seleccionar estadísticos de prueba • Correlación de Pearson • Correlación de Spearman
4	Lectura del Valor P $p = 0.0$

5 Establecer una hipótesis como aceptada

Finalmente, se llega a la conclusión de que existe correlación entre las variables y se acepta la Hipótesis Alternativa H1

Dado lo anterior, se presentan los resultados del valor de P calculados para cada algoritmo en la Tabla 46 y 47.

Tabla 46 - Valor de P para Pearson

	Sexo	Raza	Estado Civil	Ubicación	Estado	Región
Sexo	0.0	0.0	0.0	0.0	0.013489	0.559514
Raza	0.0	0.0	0.0	0.0	0.0	0.0
E. Civil	0.0	0.0	0.0	0.001976	0.0	0.0
Locación	0.0	0.0	0.001976	0.0	0.0	0.0
Estado	0.013489	0.00	0.0	0.0	0.0	0.0
Región	0.559514	0.00	0.0	0.0	0.00	0.0

Tabla 47 - Valor de P para Spearman

	Sexo	Raza	Estado Civil	Ubicación	Estado	Región
Sexo	0.0	0.0	0.000004	0.356356	0.04809	0.872099
Raza	0.0	0.0	0.0	0.0	0.0	0.0
E. Civil	0.000004	0.0	0.0	0.8079	0.0	0.0
Ubicación	0.356356	0.0	0.08079	0.0	0.0	0.0
Estado	0.04809	0.0	0.0	0.0	0.0	0.0
Región	0.872099	0.0	0.0	0.0	0.0	0.0

En base a los resultados presentados para el valor P en cada relación podemos aceptar la hipótesis alternativa (H1) de que existe una asociación entre las variables categóricas, y se procede a realizar el análisis de los resultados obtenidos en las matrices de correlación para cada algoritmo (Pearson y Spearman).

Tabla 48 - Matriz de Spearman

	Sexo	Raza	Estado Civil	Ubicación	Estado	Región
Sexo	1	-0,04884214	0,014508616	-0,002911576	0,006239525	0,000508217
Raza	-0,04884214	1	0,128141715	0,034320024	-0,338289185	-0,467261265
E. Civil	0,014508616	0,128141715	1	-0,005512044	-0,051090253	-0,089929564
Ubicación	-0,002911576	0,034320024	-0,005512044	1	-0,015979849	-0,02173254
Estado	0,006239525	-0,338289185	-0,051090253	-0,015979849	1	0,510827985
Región	0,000508217	-0,467261265	-0,089929564	-0,02173254	0,510827985	1

Tabla 49 - Matriz de Pearson

	Sexo	Raza	Estado Civil	Ubicación	Estado	Región
Sexo	1	-0,048939515	0,026686081	-0,05551577	0,00779894	0,00184217
Raza	-0,048939515	1	0,111014147	0,03366032	-0,3434814	-0,4452136
E. Civil	0,026686081	0,111014147	1	-0,00976645	-0,0458195	-0,07395742
Ubicación	-0,055515767	0,03366032	-0,009766454	1	-0,0220114	-0,01731938
Estado	0,007798943	-0,343481434	-0,045819532	-0,02201144	1	0,54711633
Región	0,001842172	-0,445213603	-0,073957417	-0,01731938	0,54711633	1

En las Tablas 48 y 49, podemos identificar tres correlaciones interesantes para las conclusiones respecto a este tópico. Las correlaciones marcadas con rojo identifican una correlación negativa, mientras que, las marcas con color verde una correlación positiva fuerte.

La primera correlación encontrada es Estado y Raza que representa una correlación negativa débil, tenemos también Región y Raza que representan una correlación negativa fuerte, finalmente Región y Estado representan una correlación positiva fuerte. Estos resultados se reflejan tanto en el algoritmo de Pearson como de Spearman.

Por otro lado, en los algoritmos de Clustering se efectuarán los métodos de evaluación correspondientes al punto anterior (7.1.1), estos comprobarán qué número de clúster es el óptimo a generar.

Primero para el algoritmo K-Modes tenemos el método del codo el cual nos genera esta comparativa:

Tabla 50 50 - Clústeres K-Modes

N° Clústeres	2	3	4	5	6	7	8	9	10
SSE	244	21149	19630	19337	18578	17778	17130	16330	16345
	372	2	3	8	1	0	8	7	9
Coeficiente de Silueta	0.22	0.21	0.21	0.20	0.16	0.16	0.12	0.16	0.16

Dada la Tabla 50 se aprecia que para la evaluación a través de la suma de errores cuadrados hay una disminución considerable en el k=3 y que sigue este ritmo a la baja hasta k=10, esta misma tendencia ocurre con el coeficiente de silueta en el cual presenta los valores más altos desde k=2 hasta k=5.

A continuación, se muestra una representación gráfica de la evaluación vía SSE y los Coeficientes de Silueta:




Figura 30 - Curva del "Codo"




Figura 31 - Coeficiente de silueta promedio para diferentes números de Clústeres **FALTA INDICAR MODELO AL CUAL SE LE APLICÓ EL COEFICIENTE DE EVALUACIÓN**

En base a estos resultados arrojados en la figura 30 y 31, se puede deducir que para este algoritmo el número de clústeres óptimo está entre 3 y 4.

Asimismo, se pondrá a evaluación los números de clústeres para Fuzzy C-Means:

Tabla 51 - Clústeres para Fuzzy C-Means

N° Clústeres	2	3	4	5	6	7	8	9	10
SSE	2518	210	81	38	23	19	12	9	8
Coeficiente de Silueta	0.56	0.49	0.44	0.41	0.40	0.35	0.31	0.30	0.28

A continuación, se muestra una representación gráfica por medio de la Suma de Errores Cuadrados (SSE) y los Coeficientes de Silueta:




Figura 32 - Método del "Codo" para FCM




Figura 33 - Coeficiente de Silueta Promedio para diferentes números de Clústeres **FALTA INDICAR MODELO AL CUAL SE LE APLICÓ EL COEFICIENTE DE EVALUACIÓN**

Como se puede apreciar en la tabla 51, en la figura 32 y la figura 33, estos métodos de evaluación al igual que al aplicarlo al algoritmo anterior nos lleva casi a la misma conclusión, es decir que el número de grupos o clústeres que se deben tomar varían entre 2, 3 y 4.

Por lo tanto, para la última fase de este proyecto de minería de datos se utilizará el algoritmo Fuzzy C-Means, esto dado los resultados del coeficiente de silueta el cual obtiene un valor de casi el doble que K-Modes y los clústeres que se obtendrán como salida y para su posterior interpretación serán 3, esto debido a que específicamente en el método del codo del algoritmo Fuzzy C-Means marca la mayor disminución del cálculo del SSE.

7.2. Determinación de próximos pasos

Dado los resultados obtenidos en los coeficientes de correlación, se procederá a interpretar estos resultados con el fin de conocer cómo están relacionadas las variables cualitativas, con el fin de identificar posibles factores asociados a los suicidios entre los años 2010 a 2019.

La correlación entre las variables proporcionará información valiosa sobre patrones y tendencias que podrían influir en la incidencia de suicidios en el país.

Por otro lado, el Clustering permitirá la caracterización de grupos o posibles perfiles de suicidios que nos permitirán identificar grupos de riesgo y características comunes que pueden ayudar a desarrollar estrategias de prevención más eficaces y programas de intervención específicos.

Estos hallazgos nos permitirán identificar grupos de población vulnerables y diseñar estrategias de prevención y apoyo más efectivas. Además, al comprender las relaciones entre estas variables e identificar grupos, podremos generar hipótesis y recomendar políticas y programas específicos que aborden los factores de riesgo identificados.

VIII. DESPLIEGUE

8.1. Modelos Descriptivos

8.1.1. Coeficientes de Correlación

A partir de los algoritmos de Correlación implementados en la fase anteriormente mencionada en el punto 7, y de todas las etapas anteriores del proyecto de minería de datos, se obtuvo la Figura 34, la cual, muestra una matriz de correlación de Spearman con cada variable en el eje x e y, y los valores de correlación en cada celda.

Los valores de correlación se muestran en una escala de colores, donde los valores más altos se muestran en rojo y los valores más bajos se muestran en azul. Esto permite visualizar fácilmente las relaciones entre las variables y detectar patrones de correlación.

CORRECCIÓN: Falta análisis e interpretación de correlaciones negativas.




Figura 34 - Matriz de Correlación Spearman

En este caso, para los valores mostrados una correlación de -1 indicaría una correlación negativa perfecta, 0 indicaría que no existe correlación entre las variables y 1 indica una correlación positiva perfecta. Dado lo anterior, podemos identificar las siguientes relaciones en la matriz obtenida en la Figura 34:

- Se identifica una relación de correlación débilmente negativa entre las variables Raza y Estado, lo que indica que algunas razas tienden a estar asociadas con ciertos estados, pero en dirección contraria. Esto indica que, si el número de suicidios de una raza en específico aumenta, no necesariamente aumentarían los suicidios por estados.
- Otra de las relaciones identificadas es una correlación débilmente negativa entre Raza y Región, lo que indica que algunas razas tienden a estar asociadas con ciertas regiones, pero en dirección contraria. Esto indica que, si el número de suicidios de una raza en específico aumenta, no necesariamente aumentarían los suicidios por regiones.
- La última relación identificada es una correlación débilmente positiva entre Estado y Región, lo que indica que algunos estados tienden a estar asociados con ciertas regiones. Esto indica que, si el número de suicidios de un estado en específico aumenta, los suicidios por región también aumentarían.

8.1.2. Clustering

CORRECCIÓN: Mejorar gráficos en el eje X, deben aparecer los nombres de las variables en vez de la codificación dada (0, 1, 2, etc).

No se menciona el algoritmo que mejor resultados arrojó para poder ejecutar el despliegue.

A raíz del algoritmo que se ha implementado tras la penúltima fase descrita en el punto 7, y de todas fases anteriores del proyecto de minería de datos se han obtenido los siguientes resultados representados gráficamente:




Figura 35 - Cantidad de personas por clúster dependiendo de la Raza

En este primer gráfico representado en la Figura 35, se puede notar una mayor cantidad de personas de la raza de tipo 1, es decir aquellas personas de tez blanca quienes representan el 29.9% del total, de otra forma tenemos que a simple vista aquellos individuos de piel blanca y morena son la mayoría con un 93%.




Figura 36 - Cantidad de personas por clústeres dependiendo del sexo

En la Figura 36 se puede observar que las personas del sexo masculino representados por el valor 0 son las que predominan la cantidad de suicidios con el 78%, y por lado de los clústeres, el que más cuantía tiene es el clúster 1 con el 41% del total.




Figura 37 - Cantidad de personas por clústeres por estado

Para la Figura 37, se ve que la mayoría del clúster 1 se ubica en los estados 25, 20 y 23 que representan los estados de Sao Paulo, Rio Grande Do Sul y Santa Catarina respectivamente se contabilizan con el 36%.




Figura 38 - Cantidad de personas por clústeres por región

En la Figura 38, en la cual se analiza la columna Región se denota nuevamente la generalidad del clúster 1 para la región 3 y 4 que encarna el Sudeste y Sur de Brasil con el 36%.




Figura 39 - Cantidad de personas por clústeres por Estado Civil

En base a la Figura 39, se puede deducir de forma visual la predominancia de nuevo del clúster 1 a través del estado civil de Soltero/a y Casado/a codificados a 2 y 0 respectivamente, en donde figuran con el 33.7%, y de manera unitaria se podría decir que el clúster 1 domina con el 43.8% entre las personas solteras.




Figura 40 - Cantidad de personas por clústeres por Ubicación

Por último, se tiene el siguiente gráfico mostrado en la Figura 40, estudia el campo de Ubicación y que una vez más se presenta la tendencia mayoritaria del clúster 1, en esta ocasión para el valor 0 que significa que el lugar del suicidio fue en el domicilio del individuo y el clúster de interés aborda el 42.4% del total de personas que fallecieron en su hogar.

A medida de la revisión de los clústeres generados en relación con cada columna, es oportuno decir que el clúster 1 es el que más destaca, por ende, se puede dar el siguiente perfil del individuo que más tendencia al suicidio tiene:

- Es de tez blanca.

- Es de género masculino.
- Se centra más en el Estado de Sao Paulo y por consiguiente en la Región Sudeste.
- Es soltero.
- El lugar de los hechos ocurre regularmente en el domicilio.

IX. CONCLUSIONES

CORRECCIÓN: Mejorar conclusiones.

La tecnología de Data Mining es útil para analizar grandes conjuntos de datos y encontrar patrones y relaciones entre variables, lo que puede proporcionar información valiosa para la toma de decisiones y mejorar la eficiencia y eficacia en los negocios. Sin embargo, se debe tener en cuenta la inversión en tecnología y software, ya que el análisis de grandes conjuntos de datos puede requerir mucho tiempo y recursos. Además, los resultados de los análisis de Data Mining deben ser interpretados cuidadosamente y validados con otras fuentes de información antes de tomar decisiones importantes.

Este trabajo nos permitió adentrarnos en el mundo del Data Mining, siendo una cúspide de los conocimientos adquiridos a lo largo de nuestra formación debido a que se debe emplear muchos conceptos vistos anteriormente. Además, cabe mencionar que es un acercamiento a la realidad del uso de datos, en donde gracias a estos, a su correcta manipulación y a las visualizaciones que se pueden crear; las empresas toman sus decisiones. Lo cual lo convierte en una piedra angular en los negocios.

El uso de los coeficientes de correlación de Spearman y Pearson nos permitió medir la fuerza y la dirección de la correlación entre variables, lo que nos ayudó a identificar patrones y relaciones entre las mismas. Además, los algoritmos Fuzzy C-Means y K-Modes, los cuales son considerados técnicas avanzadas de Data Mining, permitieron identificar patrones en los grupos del conjunto de datos trabajado, el cual constaba solamente de variables categóricas. Los resultados para efectos prácticos del estudio fueron positivos, ya que se utilizó de manera correcta los coeficientes de correlación y los algoritmos, dándonos resultados que no dictan de la realidad de las variables categóricas de las personas que cometen suicidios en Brasil y que pueden ser de utilidad a la hora de generar mejores compañías focalizadas en la prevención del suicidio.

El aprendizaje en este proyecto fue sumamente fructífero, ya que como equipo de trabajo logramos identificar la importancia del uso del análisis de datos y de la inteligencia artificial para la toma de decisiones, lo cual, en la actualidad, convierte a la inteligencia de negocios en una herramienta valiosa, permitiendo a las organizaciones tomar decisiones con un respaldo sumamente robusto de datos e información.

X. ANEXOS

10.1. Script Coeficientes de Correlación

```
1 import pandas as pd
2 from scipy.stats import spearmanr
3
4 # cargar el conjunto de datos CSV en un DataFrame de pandas
5 df = pd.read_csv('suicidios.csv')
6
7 # calcular la correlación de Spearman entre todas las variables
8 spearman_corr = df.corr(method='spearman')
9
10 # calcular el valor p de la correlación de Spearman entre todas las variables
11 spearman_p = pd.DataFrame(index=spearman_corr.index, columns=spearman_corr.columns)
12 for i in range(len(spearman_corr.columns)):
13     for j in range(len(spearman_corr.columns)):
14         corr, p = spearmanr(df.iloc[:, i], df.iloc[:, j])
15         spearman_p.iloc[i, j] = p
16
17 # imprimir los resultados
18 print('Correlación de Spearman entre todas las variables:')
19 print(spearman_corr)
20 print('\nValor p de la correlación de Spearman entre todas las variables:')
21 print(spearman_p)
```

Figura 41 - Script Spearman

```

1 import pandas as pd
2 from scipy.stats import pearsonr
3
4 # cargar el conjunto de datos CSV en un DataFrame de pandas
5 df = pd.read_csv('suicidios.csv')
6
7 # calcular la correlación de Pearson entre todas las variables
8 pearson_corr = df.corr(method='pearson')
9
10 # calcular el valor p de la correlación de Pearson entre todas las variables
11 pearson_p = pd.DataFrame(index=pearson_corr.index, columns=pearson_corr.columns)
12 for i in range(len(pearson_corr.columns)):
13     for j in range(len(pearson_corr.columns)):
14         corr, p = pearsonr(df.iloc[:, i], df.iloc[:, j])
15         pearson_p.iloc[i, j] = p
16
17 # imprimir los resultados
18 print('Correlación de pearson entre todas las variables:')
19 print(pearson_corr)
20 print('\nValor p de la correlación de pearson entre todas las variables:')
21 print(pearson_p)

```

Figura 42 - Script Pearson

10.2. Test de Chi-Cuadrado

```

1 import pandas as pd
2 from scipy.stats import chi2_contingency
3
4 # Leer el archivo CSV (u otro formato) con el dataset
5 dataset = pd.read_csv('suicidios.csv')
6
7 # Seleccionar las 6 columnas categóricas del dataset
8 columnas = ['SEXO', 'RACACOR', 'ESTCIV', 'LOCOCOR', 'estado', 'regiao']
9 datos = dataset[columnas]
10
11 # Realizar el test de chi cuadrado
12 statistic, p_value, degrees_of_freedom, expected = chi2_contingency(datos)
13
14 # Imprimir los resultados
15 print("Estadístico de prueba:", statistic)
16 print("Valor p:", p_value)
17 print("Grados de libertad:", degrees_of_freedom)
18 print("Frecuencias esperadas:")
19 print(expected)

```

Figura 43 - Script Test de Chi-Cuadrado